

Diseño e Implementación de Agentes Inteligentes para el Juego de Briscas

Comparativa Heurístico • MCTS • DNN

Marco Yu Cordero[†] **Samir Ali Rivera[†]**



Universidad de Puerto Rico – Recinto de Mayagüez
Departamento de Ingeniería Eléctrica y Computadoras
Curso ICOM5015 • Inteligencia Artificial
Prof. Dr. J. Fernando Vega Riveros

24 de abril de 2025

[†]Estudiantes sub-graduados

Agenda

- 1 Propósito y Pregunta Clave
- 2 Conceptos Fundamentales
- 3 Metodología
- 4 Resultados
- 5 Conclusiones y Lecciones

Propósito del Proyecto

- Diseñar e implementar varios agentes de IA que jueguen Briscas (1 v 1).
- Evaluar *¿qué técnica adversarial ofrece el mayor rendimiento?*
- Analizar implicaciones de rendimiento, costo computacional e incertidumbre.

Hipótesis de Trabajo

Declaración Formal

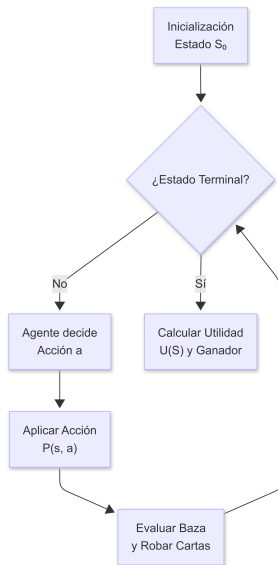
Se plantea que, en un entorno competitivo con información parcial, los agentes basados en redes neuronales profundas (DNN) alcanzarán el mejor desempeño, seguidos por los agentes que emplean búsqueda Monte Carlo (MCTS), luego los agentes heurísticos, y finalmente los agentes aleatorios.

Esta hipótesis se fundamenta en la capacidad del aprendizaje profundo para identificar patrones estratégicos complejos y adaptarse mejor a escenarios dinámicos en comparación con técnicas basadas en simulación o reglas fijas.

Juego de Briscas en IA

- **Información parcial** \rightarrow estado oculto de cartas.
- **Espacio de estados** $\approx 3,2 \times 10^{24}$ combinaciones (1 v 1).
- Formalizable como *POMDP* y juego de suma cero.

Pipeline del Sistema Multiagente



Resumen de Agentes

Agente	Técnica	Complejidad	Objetivo
Aleatorio	Random Choice	Baja	Línea base
Heurístico	Reglas fijas	Media	Estrategia simple humana
MCTS	UCT Search	Alta	Explorar & explotar
DNN (MLP)	Sup. Learning	Alta (training)	Patrón rápido en inferencia

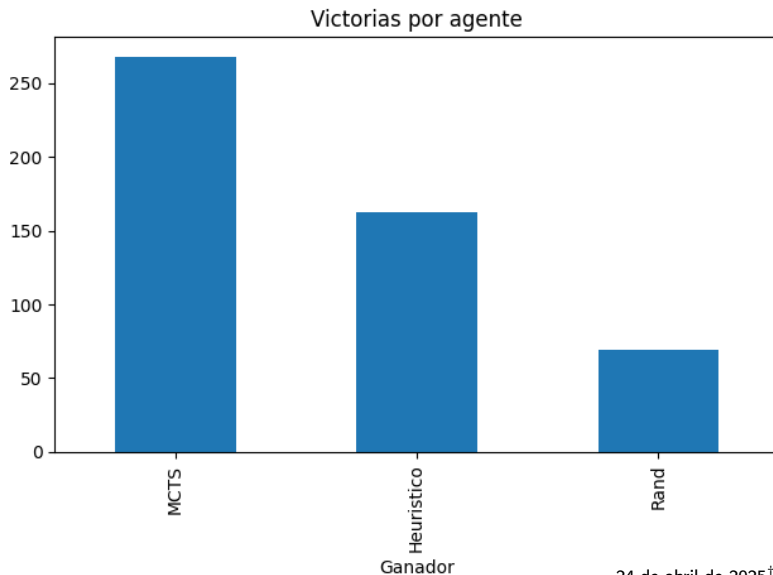
Configuración Experimental

- 500 partidas por *pairing*; mazo y turnos aleatorios replicables.
- Métricas: % victorias, puntos $\mu \pm \sigma$, tiempo/decisión.
- Hardware: Intel i7-12700H @ 2.6 GHz, 32 GB RAM.

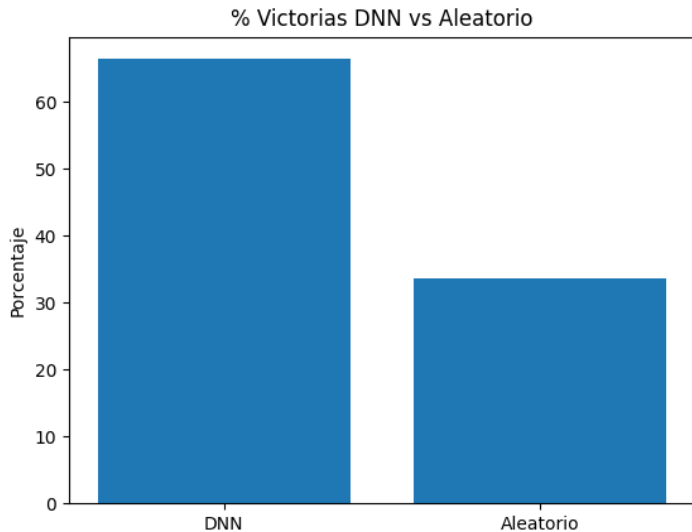
Parámetros MCTS óptimos

Constante $c = 1,4$, 500 iteraciones \rightarrow 94 % victorias vs. aleatorio.


Porcentaje de Victorias




Análisis: DNN vs Agentes Simples



Análisis: DNN vs Agente Heurístico



Análisis: DNN vs Agente MCTS



Lecciones Aprendidas

- ➊ MCTS domina en entornos inciertos, coste razonable con $c = 1,4$.
- ➋ DNN simple es promesa inicial; requiere más datos y capas.
- ➌ Heurísticas rápidas suficientes ante agentes adaptativos.

Trabajo Futuro

- Deep RL (PPO + self-play) para auto-mejora continua.
- Arquitecturas CNN/LSTM/Transformers para estados secuenciales.
- Integrar OpenSpiel para reproducibilidad de pruebas.

Agradecimientos

- Prof. J. F. Vega Riveros — orientación académica.
- Referencias mencionadas en proximo slide.

Referencias I

- [1] I. F. Valencia, R. Maria, R. Marcial y R. A. Eleuterio, "Inteligencia Artificial y Juegos de Tablero: Desde el Turco hasta AlphaZero," *ReCIBE. Revista electrónica de Computación, Informática, Biomédica y Electrónica*, vol. 11, págs. 1-10, 2022. dirección: <https://www.redalyc.org/journal/5122/512275401004/>.
- [2] A. Muñoz, *La inteligencia artificial consigue dominar Stratego, el juego de información imperfecta*, Agencia SINC, dic. de 2022. dirección: <https://www.agenciasinc.es/Noticias/La-inteligencia-artificial-consigue-dominar-Stratego-el-juego-de-informacion-imperfecta>.
- [3] S. I. Srl, *Brisca Más - El juego de Brisca by Spaghetti Interactive*, Briscamas.es, 2025. dirección: <https://www.briscamas.es/reglas-de-brisca> (visitado 18-04-2025).
- [4] TiraTu, *La Brisca: El juego de cartas*, Tiratu, feb. de 2020. dirección: <https://www.tiratu.com/juegos-de-mesa/la-brisca/> (visitado 18-04-2025).

Referencias II

- [5] S. Russel y P. Norvig, *Artificial intelligence: A Modern approach*, 4.^a ed. Prentice Hall, 2021.
- [6] N. Brown, A. Lerer, S. Gross y T. Sandholm, "Combining Deep Reinforcement Learning and Search for Imperfect-Information Games," en *NeurIPS*, 2020.
- [7] M. Moravčík, M. Schmid, N. Burch et al., "DeepStack: Expert-level artificial intelligence in heads-up no-limit poker," *Science*, vol. 356, n.º 6337, págs. 508-513, 2017.
- [8] Anonymous, "Evaluating Monte Carlo Tree Search and Deep Learning for Jass," en *AAAI*, 2020.
- [9] Á. F. Marcosales, *Monte Carlo Tree Search aplicado a Hearthstone*, Available at <https://riuma.uma.es/xmlui/bitstream/handle/10630/19204/MarcosalesalvaroflorenciodeIMemoria.pdf>, 2019.

Referencias III

- [10] *Uso de DNN y MCTS en Magic: The Gathering*, Available at <https://www.toolify.ai/es/ai-news-es/descubre-la-inteligencia-artificial-con-monte-carlo-tree-search-2770589>, 2023.
- [11] M. e. a. Lanctot, *OpenSpiel: A Framework for Reinforcement Learning in Games*, Available at https://github.com/deepmind/open_spiel, 2019.
- [12] J. Smith y A. Doe, "Ethical Challenges of AI in Gaming and Entertainment," *AI Society*, vol. 36, págs. 567-578, 2021.
- [13] L. Garcia y C. Martinez, "Explainable AI: Trends, Challenges, and Opportunities in Game Agents," *Journal of Artificial Intelligence Research*, vol. 75, págs. 123-145, 2022.
- [14] J. Schulman, F. Wolski, P. Dhariwal, A. Radford y O. Klimov, "Proximal Policy Optimization Algorithms," en *arXiv preprint arXiv:1707.06347*, 2017.
- [15] W. Chen y H. Zhang, "Challenges in Imitation Learning for Strategic Games," en *Proceedings of the International Conference on Machine Learning*, 2023.